
UNIVERSIDAD TECNOLÓGICA DE BOLÍVAR · MACHINE LEARNING
ACTIVIDAD EN CLASE · ÁRBOLES DE DECISIÓN A MANO

Período: 2026-II Versión: 01 Duración: 35 minutos

Integrantes:

● ◯ ◯ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	2.3	0.51	1
C2	3.2	0.16	0
C3	2.9	0.33	0
C4	4.3	0.41	0
C5	6.2	0.36	0
C6	1.8	0.23	1
C7	5.6	0.55	0
C8	1.8	0.62	1
C9	3.2	0.34	1
C10	1.8	0.49	1

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
razon_deuda ≤ 0.35 ingreso ≤ 3.5							
razon_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado izquierdo (los que SÍ cumplen la condición) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **ingreso ≤ 2.3** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	2.0	0.60
S2	6.0	0.21

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Ciente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	2.4	0.64	1	
P2	3.3	0.36	0	
P3	5.4	0.60	1	
P4	1.8	0.36	1	
P5	3.9	0.53	0	
P6	3.7	0.23	0	
P7	5.5	0.22	0	
P8	5.1	0.45	0	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).
 10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{VP + FP + FN + VN}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.

Período: 2026-II Versión: 02 Duración: 35 minutos

Integrantes:

● ◦ ◦ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	2.3	0.23	0
C2	2.0	0.51	1
C3	3.7	0.53	1
C4	2.9	0.23	0
C5	3.9	0.52	0
C6	4.8	0.47	0
C7	2.1	0.56	1
C8	3.0	0.36	0
C9	3.0	0.47	1
C10	4.7	0.16	0

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
razon_deuda ≤ 0.35							
ingreso ≤ 3.5							
razon_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado izquierdo (los que SÍ cumplen la condición) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **razon_deuda ≤ 0.36** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	4.1	0.44
S2	4.5	0.27

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	6.3	0.33	0	
P2	1.8	0.48	1	
P3	2.1	0.51	0	
P4	5.6	0.43	0	
P5	1.7	0.58	1	
P6	4.5	0.41	0	
P7	4.2	0.34	0	
P8	2.9	0.24	0	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).

10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{VP + FP + VN}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.

Período: 2026-II Versión: 03 Duración: 35 minutos

Integrantes:

● ◦ ◦ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	5.1	0.46	0
C2	3.6	0.42	0
C3	3.6	0.62	1
C4	5.4	0.64	0
C5	3.2	0.26	1
C6	2.0	0.20	0
C7	3.9	0.29	0
C8	6.3	0.62	0
C9	2.1	0.37	1
C10	3.6	0.52	1

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
ra- zon_deuda ≤ 0.35 ingreso $\leq$ 3.5 ra- zon_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado derecho (los que NO la cumplen) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **ingreso ≤ 3.6** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	3.6	0.43
S2	4.7	0.61

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Ciente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	4.9	0.36	0	
P2	5.2	0.27	0	
P3	1.8	0.18	0	
P4	5.9	0.40	0	
P5	4.5	0.57	0	
P6	1.9	0.60	1	
P7	5.0	0.46	0	
P8	4.4	0.57	1	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).

10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{N}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.

Período: 2026-II Versión: 04 Duración: 35 minutos

Integrantes:

● ◯ ◯ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	4.0	0.61	1
C2	2.4	0.64	1
C3	3.2	0.26	0
C4	2.7	0.56	1
C5	2.2	0.38	0
C6	1.5	0.23	0
C7	3.6	0.42	0
C8	2.1	0.50	1
C9	6.1	0.26	0
C10	2.6	0.30	0

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
razón_deuda ≤ 0.35 ingreso ≤ 3.5							
razón_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado izquierdo (los que SÍ cumplen la condición) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **ingreso ≤ 2.1** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	4.0	0.35
S2	3.7	0.54

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Ciente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	1.8	0.36	0	
P2	5.1	0.40	0	
P3	3.6	0.19	0	
P4	3.8	0.24	0	
P5	1.9	0.41	1	
P6	2.8	0.64	1	
P7	5.4	0.31	0	
P8	5.8	0.42	0	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).
 10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{VP + FP + FN + VN}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.

Período: 2026-II Versión: 05 Duración: 35 minutos

Integrantes:

● ◯ ◯ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	4.3	0.59	1
C2	1.6	0.63	1
C3	2.8	0.46	0
C4	2.4	0.34	1
C5	4.4	0.26	0
C6	4.8	0.58	0
C7	5.8	0.43	0
C8	3.5	0.20	0
C9	1.6	0.26	1
C10	5.2	0.38	0

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
razon_deuda ≤ 0.35 ingreso ≤ 3.5							
razon_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado izquierdo (los que SÍ cumplen la condición) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **ingreso ≤ 2.4** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	1.9	0.24
S2	5.0	0.54

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Ciente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	3.7	0.33	0	
P2	6.0	0.23	0	
P3	5.6	0.24	0	
P4	1.9	0.49	1	
P5	2.4	0.34	0	
P6	5.1	0.25	0	
P7	2.3	0.59	1	
P8	5.3	0.20	0	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).
 10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{VP + FP + VN}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.

Período: 2026-II Versión: 06 Duración: 35 minutos

Integrantes:

● ◯ ◯ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	4.5	0.57	1
C2	5.2	0.37	0
C3	3.3	0.63	1
C4	5.9	0.40	0
C5	4.8	0.58	0
C6	2.3	0.33	1
C7	3.6	0.28	0
C8	6.1	0.22	0
C9	3.9	0.57	1
C10	3.0	0.31	0

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
razon_deuda ≤ 0.35							
ingreso ≤ 3.5							
razon_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado izquierdo (los que SÍ cumplen la condición) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **ingreso ≤ 3.0** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	5.7	0.52
S2	2.5	0.28

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Ciente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	5.2	0.48	0	
P2	1.9	0.42	1	
P3	5.9	0.51	0	
P4	4.8	0.47	0	
P5	2.5	0.64	1	
P6	3.1	0.27	0	
P7	4.8	0.26	0	
P8	3.0	0.59	0	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).

10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{N}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.

Período: 2026-II Versión: 07 Duración: 35 minutos

Integrantes:

● ◦ ◦ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	1.9	0.63	1
C2	6.2	0.52	1
C3	3.3	0.59	1
C4	6.0	0.51	0
C5	5.3	0.25	0
C6	1.6	0.26	1
C7	6.1	0.37	0
C8	1.5	0.57	1
C9	6.1	0.54	0
C10	2.6	0.34	0

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
razón_deuda ≤ 0.35 ingreso $\leq$ 3.5							
razón_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado izquierdo (los que SÍ cumplen la condición) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **ingreso ≤ 1.9** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	2.3	0.39
S2	4.7	0.21

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Ciente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	3.1	0.37	0	
P2	2.2	0.25	0	
P3	2.9	0.61	1	
P4	1.7	0.28	0	
P5	1.6	0.24	1	
P6	2.6	0.23	0	
P7	4.1	0.24	1	
P8	3.0	0.33	0	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).

10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{VP + FP + FN + VN}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.

Período: 2026-II Versión: 08 Duración: 35 minutos

Integrantes:

● ◯ ◯ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	4.8	0.38	0
C2	5.2	0.34	0
C3	3.5	0.51	1
C4	2.9	0.27	0
C5	2.9	0.18	1
C6	5.8	0.33	0
C7	3.5	0.51	1
C8	5.3	0.37	0
C9	4.1	0.36	0
C10	6.0	0.63	1

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
razon_deuda ≤ 0.35 ingreso ≤ 3.5							
razon_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado izquierdo (los que SÍ cumplen la condición) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **ingreso ≤ 2.9** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	2.0	0.20
S2	5.3	0.50

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Ciente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	3.5	0.47	0	
P2	4.9	0.63	0	
P3	5.6	0.19	0	
P4	2.2	0.19	0	
P5	3.2	0.57	1	
P6	3.1	0.55	1	
P7	3.5	0.58	0	
P8	5.6	0.17	0	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).
 10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{VP + FP + FN + VN}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.

Período: 2026-II Versión: 09 Duración: 35 minutos

Integrantes:

● ◯ ◯ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	2.3	0.45	1
C2	4.2	0.19	0
C3	1.9	0.16	0
C4	1.9	0.57	1
C5	1.8	0.48	0
C6	6.4	0.61	0
C7	1.8	0.62	1
C8	3.4	0.49	1
C9	3.8	0.48	0
C10	5.0	0.16	0

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
razon_deuda ≤ 0.35							
ingreso ≤ 3.5							
razon_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado izquierdo (los que SÍ cumplen la condición) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **razon_deuda ≤ 0.48** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	2.0	0.54
S2	5.7	0.43

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Ciente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	4.8	0.62	0	
P2	2.2	0.28	0	
P3	5.3	0.36	0	
P4	2.9	0.55	1	
P5	4.6	0.46	0	
P6	6.4	0.35	0	
P7	4.8	0.25	0	
P8	4.4	0.48	1	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).

10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{VP + FP + FN + VN}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.

Período: 2026-II Versión: 10 Duración: 35 minutos

Integrantes:

● ◯ ◯ Sin computador, sin calculadora programable y sin IA: todo a mano.

El problema

El mismo banco, ahora con **10 clientes** en el historial. Usted va a construir **a mano el árbol de decisión**: exactamente lo que hace el algoritmo, nodo por nodo.

Cliente	Ingreso (millones)	Razón deuda/ingreso	Mora
C1	3.4	0.26	0
C2	4.0	0.59	1
C3	6.4	0.38	0
C4	5.0	0.57	0
C5	2.4	0.52	1
C6	2.4	0.21	0
C7	1.8	0.59	1
C8	3.8	0.58	1
C9	6.4	0.37	0
C10	6.4	0.15	0

Parte A · Qué tan revuelta está la caja

Con dos clases, la impureza de Gini de un grupo con proporción p de morosos es

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$$

1. Calcule p y el **Gini del nodo raíz** (los 10 clientes), con tres decimales.
2. ¿Qué valor tendría G si los 10 hubieran caído en mora? ¿Y si fueran 5 y 5? Responda sin calcular nada: solo con el significado de la fórmula.

Parte B · Elegir la primera pregunta del árbol

El algoritmo prueba cortes y se queda con el que deja las dos cajas **menos revueltas**, pesando cada caja por cuánta gente contiene:

$$G_{\text{partición}} = \frac{n_{\text{izq}}}{n} G_{\text{izq}} + \frac{n_{\text{der}}}{n} G_{\text{der}}$$

3. Complete la tabla para los **tres cortes candidatos** (tres decimales):

Corte candidato	n_{izq}	morosos izq	G_{izq}	n_{der}	morosos der	G_{der}	$G_{\text{partición}}$
ra- zon_deuda ≤ 0.35 ingreso $\leq$ 3.5 ra- zon_deuda ≤ 0.50							

4. ¿Cuál corte gana y por qué? Calcule su **ganancia**: $G_{\text{raíz}} - G_{\text{partición}}$.

Parte C · El segundo nivel

El corte ganador deja dos nodos. El lado derecho (los que NO la cumplen) todavía está **revuelto**, así que el árbol vuelve a preguntar. Use el corte **ingreso ≤ 3.8** sobre ese nodo.

- Con los clientes de ese nodo: n y morosos a cada lado, los dos Gini y el Gini ponderado del nodo después de partir.
- Dibuje el árbol completo** (dos niveles) en el recuadro: escriba en cada caja la pregunta, cuántos clientes caen y la clase de la hoja (la mayoría; si una hoja queda empatada, predice 0, que es lo que hace scikit-learn).

dibuje aquí su árbol

Parte D · Usar el árbol

7. Bajen por el árbol a estos dos solicitantes y digan la clase predicha de cada uno:

Solicitante	Ingreso (millones)	Razón deuda/ingreso
S1	4.7	0.59
S2	2.9	0.42

8. En dos frases: (a) en la actividad de KNN tuvimos que **escalar** las variables; ¿por qué el árbol **no** lo necesita?; y (b) si dejáramos crecer el árbol sin límite hasta que toda hoja quede pura, ¿qué le pasaría con clientes nuevos?

Parte E · Evaluar el árbol con clientes que no vio

El árbol se construyó con los 10 clientes del historial (el **entrenamiento**). Para saber si sirve hay que probarlo con **clientes nuevos**, de los que sí sabemos qué pasó (el conjunto de **prueba**):

Ciente	Ingreso (millones)	Razón deuda/ingreso	Mora real	Predicción del árbol
P1	4.2	0.43	0	
P2	1.9	0.50	1	
P3	3.6	0.28	0	
P4	2.1	0.56	1	
P5	5.8	0.33	0	
P6	3.0	0.57	1	
P7	6.1	0.56	0	
P8	6.4	0.41	0	

9. Baje por su árbol a cada uno de los 8 clientes y complete la columna **Predicción del árbol** (1 = mora, 0 = paga).
 10. Con **positivo = mora**, complete la matriz de confusión:

	Predicho: mora (1)	Predicho: paga (0)
Real: mora (1)	VP =	FN =
Real: paga (0)	FP =	VN =

11. Calcule, con tres decimales:

Métrica	Fórmula	Valor
Tasa base	$\max(p, 1 - p)$ de la prueba	
Exactitud	$\frac{VP + VN}{VP + FP + FN + VN}$	
Precisión	$\frac{VP}{VP + FP}$	
Recall	$\frac{VP}{VP + FN}$	

Métrica	Fórmula	Valor
F1	$\frac{2 \cdot \text{precisión} \cdot \text{recall}}{\text{precisión} + \text{recall}}$	

Parte F · Interpretar

12. ¿La exactitud de su árbol **supera la tasa base**? ¿Qué significaría que no la superara?
13. Escriba en una frase qué dice **su** precisión y qué dice **su** recall, en términos de clientes del banco (no de fórmulas).
14. Para el banco, ¿qué error cuesta más: un **FN** (prestarle a quien no paga) o un **FP** (negarle a quien sí pagaba)? Con esa respuesta, ¿preferiría un árbol con más recall o con más precisión?
15. **Del lápiz a Python.** Escriba la línea que construye en scikit-learn un árbol como el suyo, con los argumentos por su nombre, y la línea que calcula su recall.

Comprobación interna: en la tabla del punto 3, $n_{izq} + n_{der} = 10$ en las tres filas; todo Gini queda entre 0 y 0.5; y las cuatro celdas de la matriz del punto 10 suman 8.